Edge-AI Auditor: Автономна систем а виявлення корупційних аномалій у регіональних бюджетах за допом огою локальних LLM-моделей

Автор: [Твоє Прізвище та Ім'я] **Технічна база:** NVIDIA GeForce RTX 3060 (Ampere), Google Gemma 3 4B, Python.

Розділ 1. Executive Summary (Анотація проєкту)

Контроль за цільовим використанням коштів місцевих бюджетів (ОТГ) в умовах відновлення України є критичним завданням. Традиційний аудит вимагає значних людських ресурсів і часу, що створює вікно можливостей для корупційних правопорушень на етапі проведення тендерів. Використання хмарних рішень штучного інтелекту (наприклад, OpenAI GPT-4) для автоматизації цього процесу суворо обмежене вимогами державної таємниці та конфіденційності фінансових даних.

У даному технічному звіті (White Paper) представлено розробку **Edge-AI Auditor** — гібридної аналітичної системи, яка працює повністю автономно на споживчому обладнанні (Edge Computing). Система поєднує математично-статистичний аналіз (Z-Score) з мультимодальною мовною моделлю Google Gemma 3 4B.

Ключові результати прототипування:

Швидкість реакції: Виявлення аномалії та генерація повного аудиторського звіту займає менше 5 секунд на GPU середнього класу (NVIDIA RTX 3060 6GB).

Нульовий ризик витоку даних: Усі обчислення проводяться на localhost без підключення до зовнішніх API.

Висока точність кваліфікації: Модель успішно розпізнає патерни "завищення вартості робіт", "непрозорих контрактів" та генерує покрокові інструкції для детективів.

Розділ 2. Архітектура гібридного пайплайну

Для забезпечення максимальної продуктивності в умовах обмеженої VRAM (6 ГБ), архітектура системи була розділена на два незалежні модулі:

Модуль попередньої фільтрації (Python / Pandas / NumPy): Відповідає за швидку обробку масивів даних. Використовує алгоритм Z-Score для виявлення транзакцій, що відхиляються від середнього показника більш ніж на 3 стандартні відхилення (Threshold = 3.0). Це дозволяє не перевантажувати LLM рутинними цифрами.

Модуль семантичного аналізу (LM Studio / Gemma 3 4B Q4_K_M): Транзакції, що отримали прапорець "Аномалія", автоматично передаються через локальний API до квантованої мовної моделі. Модель завантажена з оптимізацією (34/34 шари інтегровано в VRAM), що забезпечує швидкість генерації на рівні 50-62 токенів за секунду.

Розділ 4. Технічні показники та стрес-тестування (Benchmarks)

Для підтвердження життєздатності концепції Edge-AI Auditor було проведено серію стрес-тестів на споживчому обладнанні. Головною метою було досягнення балансу між швидкістю генерації висновків (Inference Speed) та обмеженим обсягом відеопам'яті (VRAM).

4.1. Апаратне та програмне середовище

Обчислювальний вузол: Мобільна робоча станція (CPU: Intel Core i7-10750H, RAM: 16 GB).

Графічний прискорювач (GPU): NVIDIA GeForce RTX 3060 Laptop GPU (6 GB VRAM, архітектура Ampere).

Мовне ядро (LLM): Google Gemma-3-4B-IT.

Формат оптимізації: 4-бітне квантування (Q4_K_M) для мінімізації споживання пам'яті.

Середовище виконання: Python 3.10 (Pandas, NumPy, OpenAI API) + локальний сервер LM Studio.

4.2. Результати вимірювання продуктивності

Під час тестування модель була повністю завантажена в графічний процесор (GPU Offload: 34 із 34 шарів). Це дозволило уникнути «пляшкового горлечка» (bottleneck) при передачі даних між оперативною пам'яттю та відеокартою.

Таблиця 1. Показники швидкості та затримки (Edge-AI vs. Cloud API)

Метрика	Текстовий аналіз (Edge)	Мультимодальний аналіз (Edge Vision)	Типовий хмарний API (для порівняння)
Швидкість генерації	**62.17 токенів/сек**	34.38 токенів/сек	~40-50 токенів/сек
Латентність (Time to First Token)	**< 0.30 сек**	1.65 сек	1.0 - 2.5 сек
Споживання VRAM	~3.34 GB	~5.60 GB	Не застосовується
Залежність від Інтернету	**Відсутня (Оффлайн)**	Відсутня (Оффлайн)	Критична

4.3. Подолання апаратних обмежень (Memory Management)

Головним викликом під час розробки прототипу був ризик переповнення відеопам'яті (Memory Overflow), оскільки базова модель Gemma 3 4B у несжатому вигляді потребує понад 8 ГБ VRAM.

Застосування алгоритмів квантування (зниження точності ваг моделі з 16-біт до 4-біт) дозволило стиснути модель до 3.34 ГБ без критичної втрати аналітичних здібностей. Навіть при обробці складних візуальних графіків (графік бюджетів 2018-2022 рр.) пікове споживання пам'яті не перевищило 5.6 ГБ, залишаючи безпечний буфер у 400 МБ для операційної системи.

Висновок до розділу: Тестування доводить, що мобільна відеокарта RTX 3060 здатна генерувати аудиторські звіти зі швидкістю **понад 62 токени за секунду**. Це перевищує середню швидкість читання людини і дозволяє системі обробляти тисячі транзакцій у фоновому режимі без затримок.

Чудово! Ми на фінішній прямій. Цей останній розділ — це твоє бачення майбутнього. Інвестори та грантодавці обожнюють, коли розробник не просто показує код, а розуміє, **як це впровадити в реальне життя**.

Відкривай свій Word-документ і додавай цей фінальний блок.

---

5. Практична імплементація: Edge-AI Auditor та масштабування (Data Fabric)

На базі проведених апаратних досліджень було розроблено прототип (MVP) гібридної аналітичної системи **Edge-AI Auditor** для автоматизованого моніторингу місцевих бюджетів.

5.1. Гібридна архітектура (Z-Score + LLM) Головною проблемою використання лише нейромереж для аналізу великих фінансових масивів (Excel/CSV) є швидке переповнення контекстного вікна та VRAM. Для вирішення цього розроблено двоступеневий пайплайн:

> *Математична фільтрація:* Алгоритм Z-Score (через бібліотеку Pandas) миттєво сканує тисячі транзакцій і виділяє лише ті, що мають критичне відхилення (Threshold > 2.5).
>
> *Семантичний аналіз:* Лише аномальні транзакції передаються у локальну модель Gemma 3 4B, яка генерує детальний аудиторський висновок. Це дозволяє обробляти масиви даних будь-якого розміру на споживчому обладнанні (Edge Computing) без підключення до хмарних сервісів, гарантуючи 100% конфіденційність державних даних.

5.2. Дорожня карта та Data Fabric (2026-2027 рр.) Для національного масштабування системи запропоновано наступну стратегію:

> **Етап 1 (Пілот):** Розгортання локальних серверних вузлів в окремих ОТГ з налаштуванням ETL-пайплайнів для прямого забору даних з API Prozorro та порталу Є-Дата.
>
> **Етап 2 (Data Fabric):** Впровадження архітектури "Фабрики даних". Замість копіювання державних реєстрів у єдину базу (Data Lake), ШІ-модулі звертатимуться до розподілених баз даних у реальному часі з суворим дотриманням політик доступу (Data Governance). Це дозволить створити єдину децентралізовану антикорупційну мережу без ризиків витоку інформації.

Кінець документа.